ChatGPT

创新性分析报告

1. 理论方法创新点

1.1 乘客流失博弈建模： 本研究将乘客**流失**（Churn）行为纳入调度决策，以博弈视角平衡乘客与系统利益，这是传统方法所少见的创新。与仅在奖励中线性惩罚等待时间不同，该框架采用Logit模型估计乘客因等待过久或绕路过多而放弃乘车的概率，以“S型”函数刻画乘客耐心阈值。当车辆决策是否偏航去接候车乘客时，实际上在进行一种“隐式博弈”：若不及时服务，乘客可能改用私家车离开 [1]。传统智能调度很少显式模拟乘客弃乘行为；仅有少量运筹研究分析过乘客因等待**弃乘**对系统的影响 [1]。因此，将流失概率融入强化学习并形成乘客-运营者博弈视角是新颖的。这一方法能引导代理**权衡**：“挽留高流失风险乘客” vs. “确保当前乘客旅程不被过度延误”，从而提高系统留客率和模式转移效果。在现有文献中，我们未发现类似的RL调度工作将乘客流失行为如此明确地纳入模型，体现了理论方法上的创新价值。

1.2 CVaR风险度量引入： 本研究在优化目标中引入了**条件价值-at-风险（CVaR）**作为风险控制机制，同样具有前沿性。CVaR关注损失分布尾部的高风险部分，旨在避免最坏情形。调度中，这意味着关注**等待时间最长的一部分乘客**，防止出现极端服务崩溃情况。相比只优化平均指标的传统方法，考虑CVaR可提高策略的稳健性和公平性。例如，作者关注**最糟糕5%情形**的乘客等待/绕路风险 [2]，确保高峰压力下系统不至于崩溃。在强化学习领域，近年有工作将CVaR等风险度量用于训练风险规避策略 [3]；例如在列车控制中通过CVaR-Q学习平衡保守与常规驾驶策略 [4]。但在**智能交通调度**领域（如公交线路动态调度），将CVaR嵌入奖励函数以控制乘客流失和服务稳定性的做法尚属少见。这一风险敏感型优化在文献中缺乏直接先例，因而体现了一定的理论创新。通过CVaR，策略在训练时更关注**尾部风险**，提升了面对异常高负载情形的鲁棒性和服务保障水平 [3]。

1.3 公平性权重设计： 本文还引入了**地理公平性权重**，体现出对弱势区域乘客的关注，这是当前调度研究中的热点方向。具体做法是根据站点与中心区距离赋予额外权重，迫使策略更关注偏远、低需求区域的服务 [5]。这一设计旨在避免“**中心陷阱**”：纯粹逐利的调度往往倾向高需求区域，造成边缘区域乘客等待时间更长、服务更差 [6]。已有一些工作开始关注出行服务的公平性，例如在即时共享出行派单中增加等待时间差异的惩罚 [7]，或采用最大-最小优化提高最差用户的福利 [8]。Sun等人提出的JDRL框架通过最大化最不利司机收益来实现司机侧公平 [8]；Weitao Wu等则在定制巴士调度中显式加入乘客等待时间方差指标作为次要目标 [7] [9]。相比之下，本研究采取了**直接加权**的方法（如$W_{fair}=1+\gamma \cdot \text{距离}$），将空间公平性嵌入奖励/价值评估中。这种轻量级的公平性建模在**社区巴士动态调度**领域属新尝试。它从策略上减少冷门站点被忽视的情况，使系统兼顾效率和公平。这种做法契合交通领域对公平与效率平衡的最新趋势 [10] [11]（如同时考虑不同区域乘客等待时间差异），因此在理论方法上具有一定创新性和实际意义。

2. 系统架构设计创新

2.1 “事件驱动+真实仿真”双阶段架构： 作者设计了**双阶段训练-测试架构**，先采用事件驱动的仿真环境进行强化学习训练，再在高逼真度交通仿真（SUMO）中验证策略。**Stage 1**的事件驱动环境是一个定制的Gym模拟器，仅在乘客请求、车辆到站/乘客流失等事件发生时推进时间，从而大幅加速模拟。通过优先队列管理事件，环境可跳过空闲时段，实现>10,000步/秒的仿真速度 [12]；这使得进行上百万情景的训练成为可能。相比之下，许多既有研究采用固定时间步长（如每分钟一次决策）来模拟交通过程 [13]——这种离散时隙方法在高需求场景下效率较低，训练一个策略往往耗时很长。事件驱动RL环境的采用在**出行调度**领域是少见且创新的做法：类似思路常见于离散事件模拟，但将其与强化学习训练相结合，能显著提升收敛效率和大规模训练能力。这种加速对于处理突发**高峰事件**尤为重要，因为环境无需逐时扫描而是直接跳到下一事件。【Stage 2】则调用**SUMO**（微观交通模拟）结合真实道路网络、信号灯和车辆动力学，对Stage 1训练得到的策略进行验证 [14]。这种“双环境”设计类似于仿真到现实（sim-to-real）转移思想：在简单环境中学策略，在复杂环境中检验鲁棒性。虽然SUMO已被广泛用于交通领域RL算法的评估，但将**快速训练环境**和**高保真验证环境**解耦运用的案例

非常有限。例如，有研究采用MATSim等宏观仿真评估共享出行策略 [15] 或用微观仿真验证信号控制RL，但鲜有将两者作为训练/验证两个阶段串联的框架。因而，该**事件驱动+微观仿真**的双阶段架构在交通调度领域体现了系统设计上的新颖性：既保障了训练效率，又确保了仿真结果的现实可信度（包括信号灯延误、拥堵排队等真实因素） [16] 。这种架构有望成为今后智能交通RL研究提高训练效率和现实适用性的一种范式。

2.2 基于边特征的GNN决策（Edge-Q GNN）： 在决策算法上，作者构建了一个**边特征驱动**的图神经网络（GNN）来表示RL的Q函数，被称为“Edge-Q GNN”。传统GNN多侧重节点特征传播，而本架构显式将**候选行动（即从当前站前往下一个站的选择）**编码为图中的**边**，并提取边上的特征供GNN评估 [17] 。这些边特征包括该动作对车上乘客的额外绕路时间、由此引发的流失风险增量、违反约束的人数等 [18] 。通过Edge-Conditioned Convolution（ECC）或图注意力网络（GAT），模型可以在子图范围内**基于边信息进行卷积**，输出每条边（行动）的价值 [19] 。这一设计新颖地将**路径顺路性判断**融入了网络结构，本质上是将调度决策问题转化为**图上的边选择问题**。据调研，已有学者提出ECC网络用于一般图学习任务 [20] 或者多机器人系统中局部图信息的决策 [21] ；但在**动态车辆调度**领域，利用边驱动的GNN来近似决策价值是开创性的。例如，在乘车共享匹配中，有工作用图表示乘客与司机的匹配关系，但大多仍以节点（车辆、乘客）为中心 [22] ；将路线段作为一等公民并用GNN估值，现有文献中尚未出现。**Edge-Q GNN**的优势在于：它能够高效捕捉当前车辆可以前往不同候车点的**比较关系**，体现决策的博弈权衡——例如选择偏离路线去接一名高流失风险乘客，代价是增加车上乘客绕路时间。在本框架中，GNN通过边特征融合了这些隐含博弈因素，实现了**可解释**的策略：哪些乘客因高风险值得偏航，哪些动作因违反约束被屏蔽（Q值降为$-\infty$） [23] 。这一以**边为中心**的图网络决策机制大大区别于以往采用全局价值网络或局部规则的调度算法，属于算法架构上的一项新颖尝试。

2.3 三层次图状态表示： 为配合Edge-Q决策网络，作者构建了包含**三层要素**的图结构来表示环境状态：(i) **站点层（节点特征）**：每个站点作为节点，聚合了当前等待队列的信息（如平均流失概率、CVaR风险、等待人数、地理嵌入等） [24] 。“红色”节点特征代表需求/收益信号，包括整个站乘客的总体流失风险和尾部风险等 [24] 。(ii) **边连接层（边特征）**：站点之间的连边附加了车辆行驶和绕路成本信息（如额外行驶时间、对车上乘客最坏情况下ETA增加、CVaR风险增量等，“绿色”代价信号） [18] 。(iii) **车辆决策层**：车辆的当前位置可看作在站点图上的游走“代理”，每当到达节点（站点）时获取该节点的k跳子图 [19] ，由GNN计算连出边的Q值，从中选择下一目的站。这相当于将**车辆-乘客动态**嵌入到静态站点网络中，形成一个随车辆位置改变而**局部感知**的子图决策空间。上述设计体现了**多层图融合**思想：宏观上是固定站点网络；微观上，车辆和乘客请求在图上激活局部状态。这样的三层图表示在智能交通调度中并不常见。以往研究要么采用网格/区域划分的全局状态 [13] ，要么构建二部图匹配乘客与车辆。但这里同时考虑了**基础设施拓扑、乘客聚集态势和车辆决策语境**。类似的多层图架构可在其它领域找到一些迹象，如Yang等人将充电站、电动出租车及乘客需求构成动态异构图以协同优化 [25] ；但在社区公交调度问题上，还未见直接的先例。因而，本文通过**站点-边-车辆三层图**来组织状态信息，并配合边卷积GNN决策，达成了高效的状态表示与决策映射。这种结构化状态设计不仅提高了模型的计算效率（利用图局部性实现毫秒级推理 [19] ），也为复杂交通调度问题提供了一种新的建模范式，在系统架构上具有独创性。

3. 基线模型及增强建议

为了验证上述方法的有效性，需与当前领域有代表性的强化学习或优化调度方法进行对比。我们调研了近期**DRT/微公交调度**领域的先进基线模型，特别是那些发表于ITSC、IV、NeurIPS等顶会且提供代码实现的工作。下面汇总了一些值得纳入对比的基线方案（包括方法特点、开源情况等），可作为本研究的对照实验参考：

基线模型 (年份)	方法简述	开源代码	参考来源
JDRL (Sun et al., KDD 2022)	多智能体强化学习框架，将每个司机视为独立智能体，联合优化订单派发和车辆重定位以提高平台效率与司机收入公平性。采用**分布式策略**（每个代理训练统一策略）和**max-min公平**目标（最大化最差司机收益），并通过**分组动作表示**解决变动作空间难题 [26] [8]。在真实数据上表现出比传统调度更高的效率和司机公平度。	否（工业研究，未公开完整代码）	[27] [28]
分层RL调度 (Ma et al., NeurIPS 2021)	针对大规模动态拼车（DPDP）问题的层次强化学习框架。**高层代理**基于实时订单动态划分子问题（区域/时间片段），**低层代理**结合经典运筹学方法（如插入 heuristics）和RL策略快速求解每个子问题 [29]。这种两级优化在华为实时调度系统上验证优于传统分批优化方法。通过在不同尺度上决策，兼顾了全局最优和局部效率。 [30]	否（研究原型，无官方代码）	[30] [31]
Weitao Wu 等 (TR-Part B 2024)	提出面向混合请求（预约+即时）的动态灵活巴士调度方法，采用**多智能体深度强化学习**结合**模仿学习**和局部搜索启发式。模型利用专家插入算法生成演示，指导MARL训练以提高稳定性和解质量 [32] [33]。同时嵌入**需求预测**（利用历史OD数据）提升前瞻性，并引入**等待时间公平性**奖励，惩罚不同乘客等待差异过大的情况 [7] [9]。在广州真实数据上实验，展示了相较纯RL更高的服务成本效率和公平性。	部分开源（作者提供了核心算法代码和示例数据）	[6] [7]
HCRide (Jiang et al., IJCAI 2025)	一个面向以人为中心网约车派单的**多目标MARL**算法。通过引入“Habic”算法（调和式Actor-Bi-Critic），同时优化**乘客公平**（区域间等待时间差异）和**司机偏好**（不去不熟悉区域）等人本因素，在不显著损失总效率下提升服务体验 [34] [35]。该方法将派单建模为一个约束MDP，乘客公平作为优化目标、司机偏好作为约束，通过双Critic网络评估权衡 [11] [36]。在深圳和NYC数据集上相比现有方法提高了乘客等待公平性5%以上，且提供了公开代码。	**是**（GitHub 提供了源码 [37]）	[10] [37]
经典DRT插入启发式	传统优化基线：按顺序将新乘客请求**插入**车辆路线的算法，如“贪心最近插入”或**最佳匹配插入**。这类方法源于Dial-a-Ride问题研究，利用启发式规则满足时间窗和载客约束，计算速度快且在实际小规模场景中效果尚可 [38]。然而，它是**贪心单阶段**决策，未考虑未来到达请求，因而整体解可能次优 [39]。作为对比，它代表了不使用学习的高效基线。现代实现可借助开源工具（如OR-Tools中的路线优化库）实现。	**是**（多有开源实现，如谷歌OR-Tools等）	[39] [40]

表：当前DRT/微公交调度相关强基线方法概览。上述基线涵盖了强化学习、多智能体算法以及经典运筹优化策略，其中多项提供了开源代码，有助于对比评估。

基线增强建议： 除了上述具体模型，建议在实验中根据不同关注点设置对比：(1) **无流失建模的RL**：验证流失博弈模块的作用，可参考将本框架去掉流失相关奖励/特征的版本作为消融 baseline [41]。(2) **无CVaR的风险中性RL**：对比不采用CVaR约束时系统在极端场景下的稳定性差异。(3) **不同公平性策略**：例如对比不加权的策略网络，验证公平权重对郊区乘客服务的提升作用。如果有条件，也可将**商业运营策略**（如滴滴等平台调度规则 [42]）作为参考对照。通过上述多维度的基线比较，可以全面衡量本文提出方法在提升服务效率、降低乘客流失风险、保障公平和稳健性等方面的**相对增益**，从而符合IEEE ITSC顶会对于严谨全面实验评估的要求。

参考文献：

1. Wang, G., Zhang, H., & Zhang, J. On-Demand Ride-Matching in a Spatial Model with Abandonment and Cancellation. Operations Research, 72(3), 1278–1297, 2024 [1].

2. Chen, Y. et al. Multi-trajectory optimization for train using distributional RL with CVaR. Applied Soft Computing, 176: 113079, 2025 [3] [4].

3. Sun, J. et al. Optimizing Long-Term Efficiency and Fairness in Ride-Hailing via Joint Dispatching and Repositioning. KDD 2022: jc [8] [43].

4. Wu, W. et al. Dynamic scheduling of flexible bus services with hybrid requests and fairness: MARL with imitation learning. Transportation Research Part B, 190: 103069, 2024 [6] [9].

5. Jiang, L. et al. HCRide: Harmonizing Passenger Fairness and Driver Preference for Human-Centered Ride-Hailing. IJCAI 2025 (accepted) [35] [37].

6. Ma, Y. et al. A Hierarchical RL-Based Optimization Framework for Large-scale Dynamic Pickup and Delivery Problems. NeurIPS 2021 [29].

7. Garces, D., & Gil, S. Surge Routing: Event-informed Multiagent RL for Autonomous Rideshare. AAMAS 2024 [44] [45].

8. (其他参考了公开文献中的相关内容 [20] [25] [39]，此处略)* [20] [25].

---

[1] reijz.github.io
https://reijz.github.io/assets/papers/Matching_Spacial_Abandonment.pdf

[2] [5] [12] [14] [16] [17] [18] [19] [23] [24] [41] 基于流失博弈的社区微公交动态调度架构设计.pdf
file://file-R9peTwim3BQqNs9Cmivmkf

[3] [4] Multi-trajectory optimization for train using distributional reinforcement learning with conditional value-at-risk - ScienceDirect
https://www.sciencedirect.com/science/article/abs/pii/S1568494625003904

[6] [7] [9] [32] [33] [38] [39] [40] Dynamic scheduling of flexible bus services with hybrid requests and fairness: Heuristics-guided multi-agent reinforcement learning with imitation learning
https://eprints.whiterose.ac.uk/id/eprint/218754/1/DRT-RL-accept%20-%20Sept2024.pdf

[8] [13] [26] [27] [28] [43] Optimizing Long-Term Efficiency and Fairness in Ride-Hailing via Joint Order Dispatching and Driver Repositioning
https://engineering.purdue.edu/~lusu/papers/KDD2022.pdf

[10] [11] [35] [36] [37] [2508.04811] HCRide: Harmonizing Passenger Fairness and Driver Preference for Human-Centered Ride-Hailing
https://ar5iv.labs.arxiv.org/html/2508.04811

[15] [25] Graph-based multi-agent reinforcement learning with an enriched environment for joint ride-sharing and charging optimization - ScienceDirect
https://www.sciencedirect.com/science/article/abs/pii/S0306261925019506

20 (PDF) On the use of mechanics-informed models to structural ...
https://www.researchgate.net/publication/376586857_On_the_use_of_mechanics-informed_models_to_structural_engineering_systems_Application_of_graph_neural_networks_for_structural_analysis

21 [Literature Review] Policies over Poses: Reinforcement Learning ...
https://www.themoonlight.io/en/review/policies-over-poses-reinforcement-learning-based-distributed-pose-graph-optimization-for-multi-robot-slam

22 Bike-Share Ridership Prediction for Network Expansion Using ...
https://papers.ssrn.com/sol3/papers.cfm?abstract_id=4956159

29 30 31 A Hierarchical Reinforcement Learning Based Optimization Framework for Large-scale Dynamic Pickup and Delivery Problems
https://proceedings.neurips.cc/paper_files/paper/2021/hash/c6a01432c8138d46ba39957a8250e027-Abstract.html

34 [2508.04811] HCRide: Harmonizing Passenger Fairness and Driver Preference for Human-Centered Ride-Hailing
https://arxiv.org/abs/2508.04811

42 Ride-Hailing Order Dispatching at DiDi via Reinforcement Learning
https://pubsonline.informs.org/doi/10.1287/inte.2020.1047

44 45 Surge Routing: Event-informed Multiagent Reinforcement Learning for Autonomous Rideshare
https://www.ifaamas.org/Proceedings/aamas2024/pdfs/p641.pdf